

Material 4

- VARIABLES ALEATORIAS DE DOS DIMENSIONES - SUMA DE VARIABLES ALEATORIAS

Primera parte: VARIABLES ALEATORIAS DE DOS DIMENSIONES

El capítulo anterior trató distribuciones de probabilidad para una única variable. Sin embargo frecuentemente es útil definir en un experimento aleatorio más de una variable aleatoria.

Por ejemplo, en la clasificación de señales transmitidas, en un mismo intervalo de tiempo puede definirse una variable aleatoria X como el número de señales de alta calidad recibidas y otra variable Y número de señales de baja calidad recibidas.

En otro ejemplo, la variable X puede denotar la longitud de una pieza moldeada por inyección y la variable aleatoria Y puede ser el ancho de la misma pieza.

En ambos casos el interés recae en los valores que pueden tomar X e Y conjuntamente, y por lo tanto, el resultado de la experiencia queda definida con dos valores.

Tales situaciones son modelizadas a través del vector aleatorio o variable aleatoria bidimensional (X, Y) .

En el caso de que el resultado de la experiencia quede definido por una n -upla de valores, el modelo será un vector o variable aleatoria n -dimensional.

En general, si (X, Y) es un vector aleatorio bidimensional, el espacio muestral asociado se indica como R_{XY} (rango o recorrido del vector aleatorio) y la distribución de probabilidad que define su comportamiento se conoce como distribución de probabilidad conjunta.

4.1- VARIABLE ALEATORIA BIDIMENSIONAL DISCRETA

(X, Y) es una variable bidimensional discreta si R_{xy} es finito o infinito numerable.

4.1.1 DISTRIBUCION DE PROBABILIDAD PUNTUAL CONJUNTA

La distribución de probabilidad puntual conjunta da información sobre la probabilidad de que ambas variables del vector, al mismo tiempo, tomen dos valores determinados.

Se comienza con un ejemplo:

Dos líneas de producción manufacturan un tipo de artículo. La producción, en cualquier día dado, es de a lo sumo 3 artículos para la línea A y 2 artículos para la línea B.

Sean las variables aleatorias:

X : número de artículos producidos por día por la línea A e Y : número de artículos producidos por día por la línea B.

La siguiente tabla muestra la distribución de probabilidad conjunta del vector aleatorio (X, Y):

Y \ X	0	1	2	3
0	0,00	0,04	0,06	0,09
1	0,01	0,04	0,09	0,19
2	0,02	0,08	0,11	0,27

Por ejemplo, **0,27** da la probabilidad de que en un día la línea A produzca 3 artículos y la línea B 2 artículos. Esto se puede escribir de la siguiente forma:

$$P_{3,2} = P_{XY}(3, 2) = P(X = 3 \cap Y = 2) = P(X = 3, Y = 2) = 0,27 \text{ Probabilidad puntual conjunta}$$

En general:

$$P_{ij} = P_{XY}(x_i, y_j) = P(X = x_i \cap Y = y_j) = P(X = x_i, Y = y_j)$$

Los valores p_{ij} son tales que:

- $P_{ij} \geq 0, \forall i, \forall j$
- $\sum_{i=1}^k \sum_{j=1}^l P_{ij} = 1$

4.1.2 DISTRIBUCIONES MARGINALES

La distribución de probabilidad marginal da información sobre la probabilidad de que **una sola variable** tome un determinado valor. Es la distribución de probabilidades de una variable (como se vió en el material 3) si no se tuviera en cuenta la otra.

En el ejemplo, puede interesar conocer la probabilidad de que en un día en la línea B se produzcan dos artículos: $P(Y=2)$.

Para calcularlo se deben sumar las probabilidades de la fila $Y=2$, es decir:

$$P(Y=2) = 0,02 + 0,08 + 0,11 + 0,27 = 0,48$$

De igual forma se puede obtener la probabilidad de $Y=0$, $Y=1$ que junto con la $P(Y=2)$ constituyen la **distribución de probabilidad marginal de la variable aleatoria Y**.

De igual forma se puede obtener la distribución de probabilidades marginal de X

La tabla siguiente da (junto con la distribución de probabilidad conjunta) las distribuciones marginales de las variables X e Y:

Y \ X	0	1	2	3	Probabilidad marginal de Y $P_{.j}$
0	0,00	0,04	0,06	0,09	0,19
1	0,01	0,04	0,09	0,19	0,33
2	0,02	0,08	0,11	0,27	0,48
Probabilidad marginal de X $P_{i.}$	0,03	0,16	0,26	0,55	1,00

En general

- $P_X(x_i) = \sum_{j=1}^l P_{ij} = p_i$
- $P_Y(y_j) = \sum_{i=1}^k P_{ij} = p_j$

4.2 - VARIABLE ALEATORIA BIDIMENSIONAL CONTINUA

(X, Y) es una variable bidimensional continua si R_{xy} es infinito no numerable.

4.2.1 - DISTRIBUCION DE PROBABILIDAD CONJUNTA

Sea (X, Y) una variable aleatoria bidimensional continua. La función de densidad de probabilidad conjunta $f(x, y)$ es una función que satisface las siguientes condiciones :

- $f_{XY}(x, y) \geq 0 \quad \forall x, y \in R_{xy}$
- $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{XY}(x, y) dx dy = 1$

4.2.2 DISTRIBUCIONES MARGINALES

Al igual que en el caso discreto, a cada una de las variables que forman el vector se le puede asociar una función que modelice su comportamiento probabilístico, sin considerar el de la otra. Así se obtienen ambas distribuciones marginales:

- $f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$
- $f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$

4.3 VARIABLES ALEATORIAS INDEPENDIENTES

En el material 2 se trabajó con el concepto de independencia entre dos sucesos A y B. De ese material se puede rescatar que la idea de que dos sucesos son independientes cuando **la ocurrencia de uno no modifica la probabilidad de ocurrencia del otro**. La definición formal se realiza a través de tres ecuaciones equivalentes, una de las cuales es que $P(A \cap B) = P(A) \cdot P(B)$

De igual forma se puede definir el concepto de variables aleatorias independientes para dos variables aleatorias. X e Y son independientes cuando **la probabilidad de que una de ellas tome un valor no cambia según el valor que tome la otra**.

Y formalmente se traduce a la siguiente ecuación:

$$P(X = x_i, Y = y_j) = P(X = x_i) \cdot P(Y = y_j) \quad \forall i, \forall j \quad (\text{caso discreto})$$

$$f(x, y) = f_1(x) \cdot f_2(y) \quad \forall x, \forall y \quad (\text{caso continuo})$$

Notar que de la definición se desprende, por ejemplo para el caso discreto, que si existe al menos un par de valores para los cuales no se cumple la igualdad, las variables no son independientes.

En el ejemplo trabajado para variable bidimensional discreta se analiza si las variables X e Y son o no independientes.

$$P(X = 0, Y = 0) = 0$$

$$P(X = 0) \cdot P(Y = 0) = 0,19 \cdot 0,03 = 0,0057$$

Al ser $0 \neq 0,0057 \Rightarrow X$ e Y no son independientes.

Si bien los valores son muy cercanos, no son iguales, y ya es condición suficiente para decir que las variables no son independientes sin importar lo que ocurra con los otros pares de valores.

IMPORTANTE:

Hay que tener presente que la idea de independencia no solamente se puede analizar desde el cumplimiento de la definición. Es una característica muy factible de analizar en el contexto de un problema.

Por ejemplo: se supone que se van a ensamblar dos piezas de diferente tipo, una de tipo A y otra de tipo B. Para que ensamblen bien, la longitud de A debe ser menor a la longitud B. Ambas piezas se eligen al azar de lotes muy grandes de piezas tipo A y tipo B respectivamente. Surge la pregunta, ¿La longitud de la pieza tipo A elegida es independiente de la longitud de la pieza tipo B elegida? Y la respuesta claramente es **si**. Por el simple hecho de que fueron elegidas al azar de lotes muy grandes, podemos afirmar que el valor de una variable no puede incidir de ninguna manera en el valor de la otra. Es decir que, sin conocer la distribución de probabilidad conjunta ni las marginales, podemos afirmar que las variables son independientes.

Notar que no podría afirmarse lo mismo si las dos variables definidas fueran longitud de la pieza A y diámetro de la pieza A. En ese caso, como ambas variables están medidas en la misma pieza, es razonable pensar que las mismas pueden estar relacionadas.

4.4 COVARIANZA Y CORRELACION DE VARIABLES ALEATORIAS

En la sección anterior se definió la independencia de dos variables. La independencia es un concepto que existe o no, es decir, no se mide cuantitativamente. Sin embargo, existen distintos indicadores o medidas que pueden medir el grado de ciertos tipos de relaciones entre variables. Por ejemplo la covarianza y el coeficiente de correlación lineal miden **el grado de relación lineal** que existe entre dos variables. Si las variables son independientes, el grado de relación de cualquier tipo es nulo, incluida la de tipo lineal. La covarianza y el coeficiente de correlación, además, están íntimamente relacionados con el concepto de varianza de una variable aleatoria.

4.4.1 COVARIANZA

Dadas dos variables aleatorias X e Y , la covarianza entre X e Y denotada por $\text{Cov}(X, Y)$ se define como :

$$\text{Cov}(X, Y) = E((X - E(X)) \cdot (Y - E(Y)))$$

Trabajando algebraicamente resulta que puede expresarse:

$$\text{Cov}(X, Y) = E(X \cdot Y) - E(X) \cdot E(Y)$$

Donde, para el caso discreto, la $E(X \cdot Y) = \sum_{i=1}^k \sum_{j=1}^l p_{XY}(x_i, y_j) \cdot x_i \cdot y_j$

La covarianza toma el valor 0 cuando no hay relación lineal entre las variables y puede tomar valores positivos o negativos según el grado y signo de la relación lineal existente. Esta medida no está acotada y está influenciada por las magnitudes de los valores observados, por lo que no es fácil de interpretar.

Se demuestra fácilmente que si las variables X e Y son independientes, entonces $E(X.Y) = E(X).E(Y)$, y en consecuencia la covarianza se anula.

4.4.2 COEFICIENTE DE CORRELACION

Dadas dos variables aleatorias X e Y, el coeficiente de correlación entre X e Y, denotado por ρ_{XY} se define como:

$$\rho_{XY} = \frac{COV(X,Y)}{\sigma_X \cdot \sigma_Y}$$

Este coeficiente verifica: $-1 \leq \rho_{xy} \leq 1$

Al estar acotado, este coeficiente permite interpretar el grado de relación lineal entre las variables según si su magnitud está más cerca de 0, 1 o -1.

¿Qué significa que dos variables aleatorias tienen relación lineal?

Por ejemplo, en una situación donde se realizan backups, se definen las variables X: Espacio que ocupa la información del backup e Y: Tiempo que demora el backup. Claramente estas variables no son independientes, pero además, se puede pensar que el tiempo que demora el backup es aproximadamente proporcional al espacio que ocupa. Entonces:

- Si el tiempo fuese exactamente proporcional al espacio, habría una relación lineal perfecta entre ambas variables y el coeficiente de correlación sería igual a 1 (positivo porque la proporcionalidad es directa en este caso).
- Si además del espacio, hay otros factores que influyen en el tiempo, la relación lineal no sería perfecta y el coeficiente sería menor a 1. El valor estaría ubicado entre 0 y 1 y estaría más próximo a un valor u otro según si la situación fuese más cercana a la de relación lineal perfecta ($\rho_{XY}=1$) o a la de independencia ($\rho_{XY}=0$).

Si las variables X e Y son discretas, como en el ejemplo presentado en 4.1.1, esta relación puede notarse según si los valores cercanos a una recta son más probables que los otros. Para que se dé el caso de relación lineal perfecta, todos los valores fuera de una recta deben tener probabilidad igual a 0. Por ejemplo, la tabla de probabilidad conjunta podría ser:

Y \ X	0	1	2	3
0	0,3	0	0	0
1	0	0.4	0	0
2	0	0	0.3	0

Caso hipotético de relación lineal perfecta

En ese caso hipotético sería $\rho_{XY}=1$

Si observamos la tabla real de la distribución de probabilidad conjunta en 4.1.1 vemos que las probabilidades más altas no están en los puntos cercanos a una recta y al calcular el coeficiente de correlación con la fórmula presentada en la página anterior se obtiene $\rho_{XY}=0,0022$ (relación lineal prácticamente nula).

Importante:

Si las variables X e Y son independientes, entonces $\rho_{XY}=0$


La recíproca no es válida, si $\rho_{xy} = 0 \Rightarrow$ **ausencia de relación lineal** entre las variables. Pero esto no significa que las variables sean independientes, podría haber relación de cualquier otro tipo.

Segunda parte: SUMA DE VARIABLES ALEATORIAS

4.5 Funciones de dos o más variables aleatorias

Con frecuencia se presentan problemas en los cuales aparece una variable aleatoria en función de dos o más variables aleatorias. Veamos algunos ejemplos:

- 1 Cuatro resistores están conectados en serie. Si la resistencia del resistor i es una variable aleatoria (las resistencias se eligen de grandes lotes donde el valor exacto de resistencia varía de unidad a unidad) que notamos con R_i , entonces la resistencia del ensamble es $R = R_1 + R_2 + R_3 + R_4$
- 2 Dos partes deben ensamblarse como se muestra en la figura. El espacio libre puede expresarse como $Y = X_1 - X_2$. Donde las magnitudes X_1 y X_2 son variables aleatorias. Un espacio libre negativo significa que no puede ensamblarse.



- 3 Un sistema está formado por n componentes que funcionan independientemente. Si el tiempo transcurrido hasta la falla de la componente i es una variable aleatoria T_i , entonces el tiempo transcurrido hasta la falla del sistema es una variable aleatoria T donde
 - a) $T = \text{máx}\{T_1, T_2, \dots, T_n\}$ si las componentes están conectadas en paralelo
 - b) $T = \text{mín}\{T_1, T_2, \dots, T_n\}$ si las componentes están conectadas en serie
- 4 En una planta química, se fabrican pellets de un catalizador sólido para un reactor de hidrogenación. Se hace un control de calidad de una muestra y se cuentan los pellets que tienen defectos físicos o químicos. Se define X: *cantidad de partículas con fisuras o fracturas* e Y: *cantidad de partículas con impurezas metálica*. La cantidad total de pellets defectuosos es $S=X+Y$

Como en estos ejemplos, se puede pensar en cualquier magnitud que sea función de otras. Si estas otras son variables aleatorias, la magnitud función, también lo será. Surgen entonces interrogantes sobre la distribución de probabilidades de la variable función. ¿Su distribución está relacionada con la de las otras? ¿Se pueden obtener sus parámetros en función de los de las otras?

Existen diferentes métodos para encontrar la distribución de probabilidad de una variable aleatoria que es función de otras variables aleatorias. Solo se enuncian algunos resultados útiles que permitirán resolver numerosos problemas de la ingeniería y abordar algunos temas de la inferencia estadística, tales como la estimación por intervalos de confianza de ciertos parámetros o pruebas de hipótesis. Los resultados se limitan al caso donde la función es una combinación lineal.

4.6 Esperanza matemática y variancia para la combinación lineal de variables aleatorias

Una situación de interés es la que aparece cuando se considera una combinación lineal de n variables aleatorias $X_1, X_2, \dots, X_n$, es decir:

$$C = f(X_1, X_2, \dots, X_n) = c_1 X_1 + \dots + c_n X_n.$$

Interesa estudiar en primer término la esperanza matemática y la variancia de C bajo diferentes hipótesis.

Se comienza por analizar un ejemplo simple donde la función es una suma.

Sean X : número de piezas producidas por una máquina por la mañana; Y : número de piezas producidas por la misma máquina por la tarde.

La siguiente tabla corresponde a la distribución de probabilidad conjunta del vector (X, Y)

		X		
		1	2	3
Y	1	0.05	0.10	0.15
	2	0.05	0.35	0.3

La variable aleatoria $S = X + Y$ es el número total de piezas producidas por la máquina en un día.

A partir de la distribución conjunta del vector (X, Y) se puede determinar la distribución de probabilidad de la variable $S = X + Y$.

El conjunto de posibles valores de S es $R_s = \{2, 3, 4, 5\}$ y, sumando las probabilidades conjuntas correspondientes, se puede obtener:

- $P(S = 2) = P(X = 1, Y = 1) = 0.05$.
- $P(S = 3) = P(X = 1, Y = 2) + P(X = 2, Y = 1) = 0.15$.
- $P(S = 4) = \dots = 0.50$.
- $P(S = 5) = \dots = 0.30$.

Conocida la distribución de probabilidad de la variable aleatoria S podemos calcular $E(S)$

$$E(S) = 2.P(S = 2) + 3.P(S = 3) + 4.P(S = 4) + 5.P(S = 5) = 4.05.$$

Como actividad le proponemos calcular $E(X)$ y $E(Y)$ y verificar que:

$$E(S) = E(X + Y) = E(X) + E(Y)$$

Este resultado es un caso particular de la siguiente propiedad:

$$E\left(\sum_{i=1}^n c_i \cdot X_i\right) = \sum_{i=1}^n c_i \cdot E(X_i)$$

Le proponemos asimismo como actividad calcular $V(X)$, $V(Y)$, $V(S)$ y verificar que:

$$V(X + Y) \neq V(X) + V(Y)$$

El resultado que se verifica es $V(X + Y) = V(X) + V(Y) + 2 \cdot \text{COV}(X, Y)$. Este resultado es un caso particular de la siguiente propiedad: Si $X_1, X_2, \dots, X_n$ son n variables aleatorias independientes y $c_1, c_2, \dots, c_n$, n escalares, entonces:

$$V\left(\sum_{i=1}^n c_i \cdot X_i\right) = \sum_{i=1}^n c_i^2 \cdot V(X_i) + \sum_{i \neq j} \sum_{j=1}^n 2 \cdot c_i \cdot c_j \cdot \text{COV}(X_i, X_j)$$

Es importante detenerse a observar: si todas las X_i son **variables aleatorias independientes** entre sí, entonces la covarianza para cualquier par de variables es 0 y se obtiene:

$$V\left(\sum_{i=1}^n c_i \cdot X_i\right) = \sum_{i=1}^n c_i^2 \cdot V(X_i)$$

De estos últimos dos resultados se desprenden los resultados particulares para suma y resta de dos variables aleatorias:

1. $V(X_1 + X_2) = V(X_1) + V(X_2) + 2 \text{COV}(X, Y)$.
2. $V(X_1 - X_2) = V(X_1) + V(X_2) - 2 \text{COV}(X, Y)$.

Si las variables son independientes:

3. $V(X_1 + X_2) = V(X_1 - X_2) = V(X_1) + V(X_2)$

Notar que por más que en la función la variable aparezca sumando o restando, la variancia siempre se suma.

También notar que las propiedades involucran a las variancias. Si se suman desvíos estándar se obtienen resultados erróneos.

4.7 Modelo de la distribución de probabilidades de una combinación lineal de variables aleatorias

Así como pudo expresarse a los parámetros de la variable C en función de los parámetros de las variables X_i (con C combinación lineal de otras variables X_i), también hay propiedades que permiten afirmar que la distribución de C sigue determinado modelo, cuando se conoce el modelo que siguen las X_i . Las propiedades involucran solo algunos de los modelos estudiados en este curso. En algunos casos, la distribución de C será la misma que la de las X_i , y en otros casos no.

4.7.1 Teorema central del límite

Este teorema permite obtener una distribución aproximada para la suma de n variables aleatorias independientes con distribuciones conocidas o desconocidas, dados sus promedios y sus variancias, siempre y cuando el n° de variables que se sumen, n , sea suficientemente grande.

Sean $X_1, X_2, \dots, X_n$ un conjunto de n variables aleatorias independientes para las que se conocen $E(X_i) = \mu_i$ y $V(X_i) = \sigma_i^2$, $i = 1, 2, \dots, n$

Sea $S = X_1 + X_2 + \dots + X_n$

Se demuestra que, bajo ciertas condiciones generales, cuando k es suficientemente grande:

$$S \sim N(\mu_S; \sigma_S) \quad (\text{de manera aproximada})$$

En donde μ_S y σ_S se pueden obtener aplicando las propiedades presentadas en las páginas anteriores.

En otras palabras, si se tienen n variables aleatorias independientes, todas ellas con cualquier distribución de probabilidad o bien, con distribución de probabilidad desconocida; la variable “suma” tiene una distribución que puede ser aproximable por una Normal, si n es un número suficientemente grande.

Algunas consideraciones:

- El número mínimo para obtener una buena aproximación depende de la distribución de las variables sumadas. Cuanto más asimétricas sean dichas distribuciones, más grande deberá ser el valor de n necesario para obtener una buena aproximación.

Por ejemplo, si las variables sumadas tienen distribución Uniforme, la cual es una distribución simétrica, con sumar solamente 6 ya se obtiene una buena aproximación; pero si la distribución de los sumandos es asimétrica, es necesario sumar cantidades más grandes como 20 o 30 o en algunos casos puntuales de distribuciones muy asimétricas con colas pesadas, más de 100.

- Cuanto mayor es n , mejor se aproxima la distribución de la suma a la Normal. Por ejemplo, si se suman 20 variables, todas con una determinada distribución, la aproximación será mejor que si se suman 10 de esas variables.

- Si las variables que se suman presentan diferentes distribuciones de probabilidad, el teorema es válido si sus variancias contribuyen de manera semejante a la variancia de la suma.

- El teorema se puede aplicar también a cualquier combinación lineal de variables aleatorias ya que, por ejemplo, $C = c_1X_1 + c_2X_2 + \dots + c_nX_n$ puede escribirse como $C = Y_1 + Y_2 + \dots + Y_n$ siempre y cuando se cumpla lo afirmado en los items anteriores, es decir, que el valor de n sea suficientemente grande y que las variancias de las variables Y_i sean similares entre sí.

- El teorema también es válido cuando las variables que se suman son discretas; por ejemplo si se suma un número suficientemente grande de variables con distribución de Poisson o Binomial, la distribución de la suma tendrá distribución aproximadamente normal. La cantidad suficientemente grande depende, en Poisson, del parámetro λ de la variable suma. En Binomial de n y π conjuntamente.

De manera coloquial se puede decir que **al sumar variables aleatorias, la variable suma tiene una distribución “más parecida a la normal” que las variables sumadas.**

Ejemplo: Un proceso consta de 80 subprocesos que se ejecutan uno a continuación del. El tiempo de ejecución de cada subproceso (en minutos) es una variable aleatoria distribuida uniformemente en el intervalo (1,5) y por experiencia se considera razonable suponer son variables aleatorias independientes. Si el proceso total demora más de 260 minutos, los costos se incrementan considerablemente y la ingeniera a cargo está preocupada por la posibilidad de que ocurra esta situación. ¿Cuál es la probabilidad de que esto ocurra?

Para obtener esta probabilidad se necesita en primer lugar definir una nueva variable que totalice el tiempo de ejecución de los 80 subprocesos. Esa variable, que puede denominarse T, puede definirse como la suma de los tiempos de ejecución de cada uno de los subprocesos.

$$T = \sum_{i=1}^{80} E_i, \text{ donde } E_i \text{ es el tiempo que depara el subproceso } i, \text{ con } i \text{ de } 1 \text{ a } 80$$

En este caso, las variables E_i se distribuyen según el modelo $U(1, 5)$. De donde:

$$E(E_i) = \frac{5+1}{2} = 3 \text{ minutos}$$

$$V(E_i) = 1,333 \text{ minutos}$$


Para obtener la esperanza de la variable T y su variancia, se pueden aplicar las expresiones correspondientes, considerando además que se trata de variables igualmente distribuidas (todas con la misma esperanza y la misma variancia).

$$E(T) = \sum_{i=1}^{80} E(E_i) = 80 \cdot 3 = 240 \text{ minutos}$$

$$V(T) = \sum_{i=1}^{80} V(E_i) = 80 \cdot 1,333 = 106,66 \text{ minutos}^2 \rightarrow \sigma_T = 10,33 \text{ minutos}$$

Resta ahora definir el modelo que sigue la distribución de probabilidad de la variable T. Como es una suma de una gran cantidad de variables independientes ($n = 80$), se puede aplicar el Teorema Central del Límite para afirmar que T tiene una distribución que se puede aproximar a la Normal.

Obtenida la distribución de probabilidades del tiempo de producción de las máquinas, T, se puede calcular la probabilidad pedida, $P(T > 260 \text{ minutos})$, la cual resulta 0.0264. Esta nos indica que, pensando en un gran número de veces que se ejecuta el proceso, en el 2,64 % de las mismas, el tiempo de ejecución será superior a 260 minutos. En la Figura debajo se presenta la distribución de probabilidad de la variable T y se puede señalar en ella la probabilidad de interés.



4.7.2 Propiedad reproductiva de la distribución normal

A partir de comprender conceptualmente el Teorema Central del Límite, se puede deducir fácilmente que si las variables que se suman (X_i) tienen distribución normal, entonces S también la tendrá. Esto se formaliza mediante la siguiente **propiedad reproductiva** (este término refiere a que la variable suma “reproduce” la misma distribución que las sumadas):

Sea $C = c_1X_1 + c_2X_2 + \dots + c_kX_k$, donde $X_i \sim N(\mu_i, \sigma_i) \forall i$, entonces:

$$C \sim N(\mu_C, \sigma_C)$$

En donde μ_C y σ_C se pueden obtener aplicando las propiedades presentadas en las páginas 7 y 8.

La suma o resta de variables son casos particulares donde puede aplicarse la propiedad reproductiva

Ejemplo:

A un empleado de una empresa se le asigna un espacio (digital) para que utilice en sus tareas laborales. Este espacio asignado es aleatorio, entonces puede considerarse que es una variable aleatoria E , de la que se conoce que está distribuida normalmente con promedio 16 GB y desvío estándar 2 GB. Por otro lado, el espacio que un empleado ocupa con sus tareas también es una variable aleatoria X , distribuida normalmente con promedio 12 GB y desvío estándar 3 GB.

La variable $D = E - X$ compara ambos espacios e informa si el espacio asignado es suficiente:

- Si $D < 0$, el espacio asignado no es suficiente y se le debe asignar uno adicional.
- Si $D > 0$, el espacio asignado es suficiente.

Si interesa, por ejemplo, calcular la probabilidad de que no se requiera espacio adicional, se debe conocer la distribución de probabilidad de la variable D .

De las variables E y X se conoce su distribución. Además, como el espacio se asigna de antemano sin conocer nada del empleado, es razonable suponer que se comportan de manera independiente.

¿Qué puede decirse de D ?

Aplicando las expresiones relativas a la esperanza de una diferencia de variables aleatorias y a la variancia de una diferencia de variables aleatorias independientes, se obtiene que:


$$E(D) = E(E - X) = E(E) - E(X) = 16 \text{ GB} - 12 \text{ GB} = 4 \text{ GB}$$

$$V(D) = V(E - X) = V(E) + V(X) = 2^2 + 3^2 = 13 \text{ GB}^2 \rightarrow \sigma_D = \sqrt{V(D)} = 3,6055 \text{ GB}$$

Pero no alcanza con conocer la esperanza y la desviación estándar de la variable D . Se requiere conocer el modelo correspondiente a su distribución de probabilidades. En este caso, dado que D es una combinación lineal de dos variables independientes que se distribuyen según el modelo normal, se puede aplicar la propiedad reproductiva de la distribución Normal y afirmar que D también se distribuye según dicho modelo. Entonces:

$$D \sim N(4 ; 3,6055)$$

Conocido el modelo, se pueden obtener diferentes probabilidades y caracterizar el comportamiento de la nueva variable. En la Figura debajo se presenta la distribución de la diferencia entre ambos diámetros y se señalan algunas probabilidades. Se observa que el 13,33 % de las veces, el espacio asignado será insuficiente y deberá asignarse uno adicional.



4.7.3 Otras distribuciones que verifican la propiedad reproductiva

En los siguientes modelos se puede aplicar la propiedad reproductiva (solo para suma), suponiendo que las variables que se suman son independientes entre sí:

- Distribución Binomial (todas tienen que tener el mismo π)
- Distribución Poisson
- Distribución Chi cuadrado (se presenta en la unidad siguiente)

Para pensar: Si la suma de variables “tiende a la normal” y hay distribuciones diferentes a la normal que verifican la propiedad reproductiva, ¿es una contradicción?

No, la contradicción es salvada por el hecho de que los tres modelos mencionados **pueden aproximarse con la normal para valores grandes de sus parámetros** (n y λ respectivamente).